Долговременная динамика блочной языковой генерации, обусловленной собственным текстом, после вытеснения промпта

Semantic Afterlife

Adam Cage

Abstract

Что сохраняется, когда языковая модель продолжает собственный текст после того, как исходный промпт покинул её вход? Мы изучаем блочный re-prompt: каждый вызов получает текущий конечный хвост, а события остановки записываются, не завершая траекторию. Мы различаем достижение заданного горизонта, вход в текстовый режим повторения и зазор в пространстве представлений между траекториями от разных и одинаковых начальных текстов. Репликация эксперимента с занятостью пространства у модели через внешний API устанавливает положительный зазор в последней полосе во всех трёх пространствах представлений; для BGE-M3 он равен 0.208 с 95%-интервалом $[0.091, 0.314]$. Локальная матрица семейств сравнивает базовые и дообученные версии Qwen, OLMo, Ministral и Gemma. Порядок версий по доле завершённых траекторий различается между семействами. У Qwen и Ministral зазоры NF4 положительны в обоих пространствах, а у Gemma Base зазор в BGE-M3 установленно отрицателен, и знак в Qwen-embedding не установлен. У Qwen режим повторения обычно подтверждается до полного вытеснения промпта и сохраняется после него. В отдельном продолжении отобранных режимов наблюдается 0/8 подтверждённых выходов через 4,999,168 исходных токенов на траекторию с цензурированием на 1220.5 оборота окна от первого токена короткой серии. Это условные наблюдения поверхностного повторения и зависимости от начального текста на конечном горизонте. Они не устанавливают ни восстановление семантической памяти, ни валидированные метастабильные семантические состояния. Измеренное ядро использует новые блочные промпты вместо нативного скользящего внимания; его результаты не устанавливают напрямую поведение обычного чата или автономных агентов.

1 Введение

Пусть W — заданное нами скользящее окно в токенах генератора, а B — размер блока, запрашиваемого при каждом вызове. Объект статьи — не поточное скользящее внимание на уровне токенов, а блочный re-prompt собственного хвоста модели. На шаге k вход X_k состоит из последних $\min(|\cdot|, W)$ токенов начального текста и всего сгенерированного к этому моменту продолжения. Модель выдаёт блок, после чего окно сохраняет только хвост:

$$Y_k^{(B)} \sim P_\theta(\cdot \mid X_k; B, \text{temperature}), \qquad |Y_k^{(B)}| \le B, \qquad X_{k+1} = \text{Tail}_W\big(X_k \oplus Y_k^{(B)}\big). \tag{1}$$

Каждый вызов начинается заново. Индексы позиций сбрасываются, а кэш ключей и значений не переносится из предыдущего вызова. Когда модель выдаёт токен остановки, это событие записывается, и хвост отправляется снова. Таким образом, измеряется извне поддерживаемое продолжение собственного текста после повторных попыток завершиться. Это не неограниченная цепь с поглощающим состоянием конца последовательности, не обычный чат и не автономный агент.

Горизонт — число сгенерированных токенов, при котором начальный текст полностью покинул окно. Для непустого начального текста это число равно W, то есть обороту $T/W = 1$, где T — число

сгенерированных токенов. Вытеснение может начаться раньше, в момент $W - L_0$, когда окно впервые заполняется и следующий токен может вытеснить токен начального текста. Это два разных момента. Полное вытеснение происходит на обороте 1.

Вопрос, на который позволяют ответить измерения, уже теории семантической памяти. Может ли продолжение собственного текста сохранять текстовые повторы после физического удаления исходного промпта, и могут ли траектории по-прежнему зависеть от того, с какого текста они начались? Различаются ли достижение горизонта и устойчивость этих режимов между семействами и версиями моделей? Для реально выполненных процессов ответ таков: повторы могут сохраняться долго, зазор между траекториями от одинаковых и разных начальных текстов может оставаться положительным после вытеснения, а достижение горизонта и этот зазор зависят от семейства и версии модели. Эти результаты представлены в разделе 4. В разделе 4.5 перечислены вопросы, которые та же программа исследования не разрешила, включая время полураспада семантической памяти, валидированные метастабильные состояния и переходные токи. Эти ограничения определяют область выводов.

2 Связанные работы

Текстовое повторение при нейросетевом декодировании — известный режим. Holtzman et al. (2020) показывают, что декодирование с максимизацией правдоподобия попадает в повторяющиеся циклы, и предлагают nucleus sampling как способ борьбы с ними внутри одной генерации, обусловленной промптом. Xu et al. (2022) измеряют самоподдерживающийся цикл: предложение, которое уже появилось в контексте, становится более вероятным продолжением. Обе работы анализируют вырождение внутри одной генерации. Они дают подходящее альтернативное объяснение режима повторения. Они не измеряют хвост, который подаётся обратно как следующий промпт после того, как исходный текст покинул конечное окно.

Zekri et al. (2024) представляют авторегрессионную модель с конечным окном как марковскую цепь на токенных строках и доказывают единственность стационарного распределения для своего ядра токенной выборки при положительной температуре и полном носителе. При выполнении её предпосылок эта теорема исключает несколько стационарных законов для токенной цепи. Она не измеряет занятость пространства после вытеснения начального текста и не позволяет интерпретировать положительный зазор эмбеддингов как второе стационарное распределение.

Циклы возникают и тогда, когда модель просят преобразовать целый текст. Wang et al. (2025) итерируют перефразирование и находят циклы низкого порядка, обычно периода два, которые сохраняются при повышении температуры. Geng et al. (2026) определяют марковскую цепь генераций, где каждый шаг видит шаблон промпта и предыдущий результат, но не более раннюю историю. На итеративном перефразировании и обратном переводе они уже измеряют лексический и семантический дрейф между последовательными итерациями, в том числе оценками перекрытия и сходством эмбеддингов, и различают ранние точные возвраты и более длинные переходные процессы. Их шаг заменяет весь текст согласно инструкции. Уравнение (1) добавляет блок к растущему потоку, а затем отбрасывает все токены за пределами последних W, включая исходный промпт, когда число оборотов достигает 1. Протоколы «испорченного телефона» также передают весь предыдущий текст с инструкцией (Perez et al., 2025; Mohamed et al., 2025). Ko & Geiping (2026) отслеживают траектории в пространстве представлений для многошаговых бесед с собеседником. В нашем протоколе одна модель и нет второй политики. Wang et al. (2026) сохраняют промпт в кэше и вытесняют сгенерированные токены рассуждения. Мы вытесняем начальный текст и продолжаем хвост. StreamingLLM (Xiao et al., 2024) изучает сохранение токенов, служащих стоками внимания, и потоковую работу с конечным кэшем, включая базовый вариант с пересчётом скользящего окна. Его оценка на длинном потоке измеряет перплексию на внешнем текстовом корпусе. Здесь развивающееся состояние состоит из собственного текста модели, начальный текст полностью вытесняется, а измеряемые исходы — достижение горизонта, повторение и разделимость, обусловленная начальным текстом. Вклад состоит в этом эмпирическом сочетании; приоритет в потоковой работе или работе на миллионах токенов не заявляется.

Chen et al. (2026) разделяют горизонт задачи, число токенов, к которым модель может обращаться, и память как систему, сохраняющуюся между шагами. Мы используем это различение в терминологии.

W — заданное окно. Число оборотов T/W — длительность наблюдения процесса. Мы не добавляем поиск, рабочие записи или резюме. Статья не показывает, что агенты с длинным горизонтом тем самым получают память, и не предлагает способ устранения дрейфа, провалов задач или низкого качества длинного текста. Коллапс при обучении на рекурсивно сгенерированных данных (Shumailov et al., 2024) — другой объект: в этих запусках переобучения нет.

Вклад состоит в сочетании пяти решений. Исходный промпт учитывается до полного выхода из W. Достижение горизонта, текстовый режим повторения и различимость начальных текстов измеряются раздельно, чтобы режим среди выживших не приняли за высокую вероятность достижения горизонта. При сравнении семейств и дообученных версий сохраняются неудавшиеся клетки. Отобранные режимы наблюдаются далеко за горизонтом с явным указанием момента цензурирования. Интерпретация отделяет эти наблюдения от восстановления фактов, семантического времени полураспада, валидированных состояний и постоянных режимов. Время полураспада, ток между семантическими состояниями и валидированная марковская модель состояний не входят в этот вклад. Инструменты молекулярной динамики, применённые на раннем этапе (Wu & Noé, 2020; Paul et al., 2019), описаны в разделе 4.5, поскольку необходимая валидация не была пройдена.

3 Методы

3.1 Блочный re-prompt после попыток завершиться

Протокол P1 на каждом шаге отправляет Tail_W как новый промпт. Это единственный протокол в представленных ниже результатах. Нативная скользящая маска с непрерывным кэшем ключей и значений, протокол P2, не измерялась. Внутри одного вызова модель может обращаться к токенам, которые только что выдала в том же блоке, вплоть до B токенов, поэтому P1 также не является скольжением по одному токену. Выводы относятся к этому продолжению собственного текста. Они не описывают автоматически обычный чат, агентов с инструментами или кэш, который только обрезается с левого края.

Экспериментальный движок не считает конец последовательности концом траектории. В эксперименте с занятостью пространства у доменных траекторий в последней четверти запуска средняя доля заполнения блока равна 0.853 с интервалом $[0.756, 0.936]$, а средняя доля вызовов, завершившихся не по ограничению длины, — 0.359. Генерация продолжается, потому что остановка переопределяется. Минимальная длина ответа на стороне провайдера не задаётся.

Единица анализа — неперекрывающийся фрагмент из 1024 токенов генератора, вырезанный только из сгенерированного потока. Начальный текст во фрагмент не входит. Число оборотов равно T/W. Контраст в последней полосе, на полосе оборота 12, измеряется после горизонта, который соответствует обороту 1. Это не свидетельство того, что режим повторения возник после горизонта.

3.2 Два дизайна, одно ядро

Оба дизайна используют уравнение (1) с W=4096 и B=1024, то есть B/W=0.25, при температуре 0.3. Они не объединяются.

Эксперимент с занятостью пространства использует instruct-генератор `or-qwen3-8b` через внешний API, механизм продолжения `raw_completion`, провайдера Alibaba на завершённых шагах и целевой горизонт двенадцать оборотов. Каждый из десяти доменных текстов запускается дважды. Парные тексты-близнецы — отдельный контраст с низкой статистической мощностью, который не выносится в основные результаты. Эксперимент был сгенерирован дважды. Вторая генерация — репликация, используемая как доказательство в разделе 4.2. Каталоги эмбеддингов первой генерации не подлежат восстановлению (раздел 3.4).

Матрица семейств выполняется локально. Базовые и дообученные версии получают одни и те же байты начальных текстов (`raw_bytes`). Основное квантование — NF4. Строки INT8 — ограниченные проверки согласованности. Заданный горизонт — двенадцать оборотов, T=49152 токена. Семейства представлены

Qwen3-8B Base и Instruct, линией OLMo-3-7B Base, SFT, DPO и RLVR, Ministral-3-8B Base и Instruct, а также Gemma-4-12B Base и версией, дообученной на инструкциях. Каждая клетка NF4 содержит десять фиксированных начальных текстов с четырьмя стохастическими потомками каждого, то есть сорок запланированных траекторий. Траектория, завершившаяся после повторных пустых ответов, остаётся в подсчёте достижения горизонта. Это недостижение горизонта, а не успешная траектория без повторения. Позднейшая когорта продолжает восемь клеток с уже подтверждённым режимом повторения далеко за двенадцать оборотов (раздел 4.4).

В банке начальных текстов каждой доменной метке соответствует один текст, по форме предназначенный для продолжения. Тема, лексика и регистр связаны между собой. Зазор между начальными текстами — зависимость от этого исходного текста. Он не отделяет смысл от стиля.

3.3 Достижение горизонта, режим повторения, зазор и выход

Четыре величины сообщаются раздельно.

Достижение горизонта — число запланированных траекторий, получивших статус завершённых на заданном токенном горизонте. Это не доля режимов повторения среди завершившихся.

Текстовый режим повторения — вердикт о поверхностной форме. Фрагмент считается зацикленным, когда доля повторяющихся 3-грамм превышает 0.083, то есть 99-й перцентиль эталона Кэрролла и Дарвина при том же размере фрагмента. Траектория считается вырожденной, когда зациклены не менее половины её фрагментов после горизонта либо когда медианный коэффициент Жаккара по шинглам в позднем окне достигает 0.0122. Это альтернативные критерии. В матрице семейств режим повторения подтверждается после трёх последовательных строк фрагментов с пофрагментным флагом зацикливания. Три фрагмента по 1024 токена составляют 0.75 оборота — самый ранний момент срабатывания правила. Правило отмечает текстовый режим, близкий к рекуррентному. Это не тест точного периода 1 и не семантическое состояние. Такое название допустимо только для валидированного марковского макросостояния. Ни одно не прошло валидацию (раздел 4.5).

Зазор, обусловленный начальным текстом, на полосе оборотов равен $G = D_{\text{between}} - D_{\text{within}}$, где используется косинусное расстояние между L2-нормированными эмбеддингами фрагментов. D_{within} усредняет пары с общим начальным текстом. D_{between} усредняет пары с разными начальными текстами. Знак считается установленным, когда опубликованный 95%-интервал исключает 0. Если интервал включает 0, знак не установлен. Неидентифицированная полоса без пар между разными начальными текстами не является сменой знака и не изображается нулём. Репликация эксперимента с занятостью пространства использует бутстрэп по траекториям с сохранением кратностей. Матрица семейств использует кластерный бутстрэп по начальным текстам, который перевыбирает начальные тексты и сохраняет кратности их потомков. Фрагменты не считаются независимыми репликами. Для подходящих клеток проведён анализ с последовательным исключением одного начального текста; разреженные клетки, не позволяющие такой анализ, остаются явно помеченными. Это интервалы разных оценивателей, и они не объединяются. Пространства представлений — BGE-M3 и Qwen3-Embedding-8B для матрицы семейств; в эксперименте с занятостью пространства к ним добавляется Gemini-Embedding-001. Пространства не приводятся к общей шкале.

Для выхода нужны три последовательные незацикленные строки фрагментов после подтверждённого режима повторения. В длинной когорте часы начинаются с первого токена серии из двенадцати оборотов. τ_{escape} остаётся пустым, если выход не подтверждён. Момент цензурирования — общая остановка, а не оценённое среднее.

3.4 Что можно пересчитать

Указанные каталоги запусков первой генерации эксперимента с занятостью пространства и её эмбеддингов утрачены. Закоммиченные интервалы последней полосы этого эксперимента — архивные результаты анализа. Их нельзя пересчитать по исходным векторам, а новая стохастическая реализация их не восстанавливает. Репликация — новая генерация из 28 траекторий. Она служит основным доказательством зазора занятости. Архивные интервалы сохранены в разделе 4.2 как историческая запись того

Таблица 1: Основное доказательство занятости: зазор последней полосы, обусловленный начальным текстом, на новой генерации репликации, десять доменных текстов, 95%-интервал бутстрэпа по траекториям. Разделимость означает, что интервал исключает 0 с положительной стороны. В последней полосе n_{within}=6. Генерация `s5-lock-occupancy-repl-20260907T091450Z-e8452acb`.

Пространство	зазор	95%-интервал	разделимость
BGE-M3	0.208	$[0.091, 0.314]$	да
Qwen3-Embedding-8B	0.400	$[0.221, 0.590]$	да
Gemini-Embedding-001	0.152	$[0.073, 0.239]$	да

отдельного эксперимента. Утрата этих каталогов не позволяет утверждать, что все более ранние числа проекта невоспроизводимы.

4 Результаты

4.1 Повторение, часто подтверждённое до горизонта

В эксперименте с занятостью пространства 19/20 доменных траекторий удовлетворяют правилу режима повторения, а 10/10 доменных начальных текстов дают хотя бы один такой режим. Траектория без режима повторения — один из двух запусков `love` (1/2). Интервал Клоппера–Пирсона для 19/20 равен $[0.751, 0.999]$. Это один instruct-генератор, один протокол и температура 0.3. Это не частота для языковых моделей как класса. На отдельной оси моделей через внешний API при том же W и n=4 на клетку `or-gemma-4-31b` даёт 0/4 при температурах 0.3 и 1.0, а `or-gpt-oss-120b` — 4/4 при обеих.

Таблица режимов повторения Qwen3-8B в матрице семейств показывает, когда срабатывает флаг. После удаления двух копий каждой траектории для разных эмбеддингов все 86 завершённых траекторий имеют подтверждённый режим повторения и ни у одной нет подтверждённого выхода через двенадцать оборотов. Из 69 траекторий NF4 у 67 режим подтверждается на 0.75 оборота (Base 31/31, Instruct 36/38), а у двух остальных траекторий Instruct — на 1.00. Полное вытеснение происходит на обороте 1. Значение 0.75 также является нижней границей правила подтверждения. Поэтому таблица фиксирует повторение, которое правило может отметить до полного выхода начального текста из окна либо, для двух траекторий, в момент этого выхода. Она не фиксирует режим, впервые обнаруживаемый только после горизонта. В меньших строках INT8 того же файла 16/17 соответствуют 0.75, а 1/17 — 1.00: это та же пара моментов, а не отдельный результат о времени возникновения.

4.2 Зависимость от начального текста

Основное доказательство — репликация эксперимента с занятостью пространства. Дизайн содержит десять фиксированных доменных текстов и двадцать запланированных доменных траекторий. Зазоры последней полосы положительны во всех трёх пространствах представлений (таблица 1). В BGE-M3 зазор равен 0.208 с интервалом $[0.091, 0.314]$. В Qwen3-Embedding-8B — 0.400 $[0.221, 0.590]$. В Gemini-Embedding-001 — 0.152 $[0.073, 0.239]$. Каждый интервал исключает 0 с положительной стороны. Уровни не взаимозаменяемы между пространствами. Четыре доменные траектории заканчиваются на 47 фрагментах вместо 48, поэтому в последней полосе n_{within}=6 вместо полного набора пар с одинаковым начальным текстом. Полоса 10 также исключает 0 на полном наборе пар. Это не предзарегистрированное число последней полосы.

Это зависимость от начального условия после того, как соответствующий текст покинул окно. Траектории от одинакового начального текста остаются ближе, чем траектории от разных текстов. Зазор не показывает, что модель помнит исходные факты, может восстановить промпт или сохраняет смысл независимо от стиля. Родственные траектории могут просто продолжать сходные семейства повторов. В этой репликации флаг вырождения истинен у 20/20 доменных траекторий, поэтому зазор измерен среди запусков в режиме повторения.

Таблица 2: Исторический эксперимент с занятостью пространства. Опубликованные интервалы последней полосы первой генерации. Исходные векторы не подлежат восстановлению (ADR-0021). Не основное доказательство; эти интервалы не заменяют таблицу 1. n_{within}=9.

Пространство	зазор	95%-интервал	разделимость
BGE-M3	0.201	$[0.065, 0.332]$	да
Qwen3-Embedding-8B	0.390	$[0.151, 0.593]$	да
Gemini-Embedding-001	0.150	$[0.029, 0.266]$	да

Таблица 3: Завершённые траектории на горизонте двенадцати оборотов, NF4, температура 0.3, W=4096, по сорок запланированных на клетку. Пустые ответы остаются в знаменателе.

Семейство	Версия	Завершено
Qwen3-8B	Base	31/40
Qwen3-8B	Instruct	38/40
OLMo-3-7B	Base	27/40
OLMo-3-7B	SFT	19/40
OLMo-3-7B	DPO	3/40
OLMo-3-7B	RLVR	4/40
Ministral-3-8B	Base	40/40
Ministral-3-8B	Instruct	40/40
Gemma-4-12B	Base	38/40
Gemma-4-12B	дообученная на инструкциях	0/40

Первый эксперимент с занятостью пространства имеет историческое значение (таблица 2). Его опубликованные интервалы также исключают 0 в тех же трёх пространствах, а пересчёт по закоммиченной матрице пар начальных текстов совпадает с опубликованными точками с точностью до 0.002. При последовательном исключении одного начального текста зазоры по этой матрице остаются положительными; минимальный равен 0.128. Эти проверки используют закоммиченную матрицу. Они не восстанавливают интервалы бутстрэпа по траекториям, поскольку эмбеддинги утрачены. Таблица 2 не служит основным доказательством, и её интервалы не являются интервалами репликации.

4.3 Семейства и версии моделей

Достижение 49152 токенов — иной факт, чем режим повторения среди достигших этого горизонта запусков (таблица 3). Строки не образуют объединённую частоту и не задают единый эффект дообучения на инструкциях. Одинаковые или близкие числа завершённых траекторий не доказывают эквивалентность.

Qwen3-8B Instruct достигает горизонта чаще Base (38/40 против 31/40). Девять неудач Base и две неудачи Instruct — пустые ответы, сохранённые в выборке. Меняется и состав выживших начальных текстов. У Base `recipe` даёт четыре неудачи с пустыми ответами и ни одной строки в таблице режимов повторения; у Instruct `recipe` режим подтверждён в 4/4 случаях. Среди завершившихся интервал последней полосы исключает 0 в обоих пространствах, а опубликованная таблица режимов не содержит подтверждённых выходов. Base в BGE-M3: 0.147591 $[0.0691844, 0.158049]$; Instruct в BGE-M3: 0.151367 $[0.0871001, 0.159001]$. Base в Qwen3-Embedding-8B: 0.233299 $[0.117225, 0.244196]$; Instruct в Qwen3-Embedding-8B: 0.304616 $[0.191654, 0.315201]$. Совпадение этих знаков — утверждение о завершившихся траекториях. Оно не означает эквивалентность двух версий и соседствует с разными числами завершений.

В линии OLMo-3-7B число завершённых траекторий падает по ходу дообучения: 27, 19, 3 и 4 из 40. На DPO и RLVR почти все запланированные запуски не достигают горизонта. Интервалы Base исключают 0 в обоих пространствах: BGE-M3 0.0943909 $[0.0287692, 0.107647]$, Qwen3-Embedding-8B 0.189111 $[0.0861319, 0.221421]$. Для SFT в BGE-M3 получено 0.10178 $[-0.0069993, 0.121757]$, поэтому этот знак не установлен; в Qwen3-Embedding-8B — 0.1757 $[0.0342047, 0.205525]$, где интервал исключает 0. У

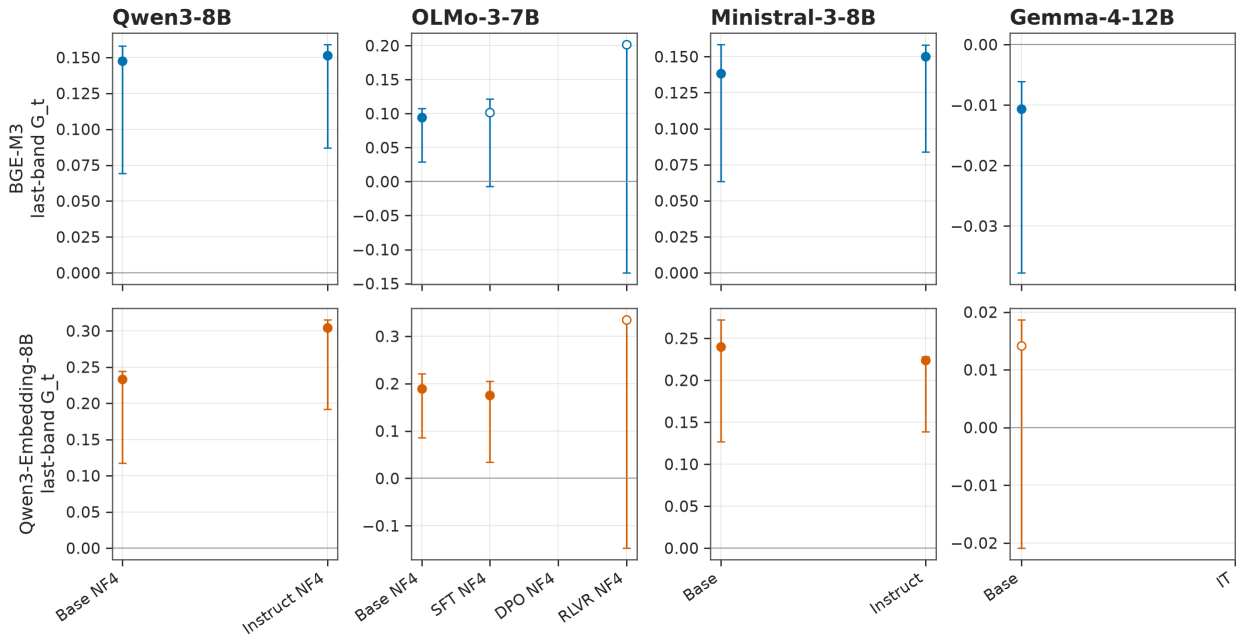


Рис. 1: Зазор последней полосы NF4, обусловленный начальным текстом, в исходном пространстве эмбеддингов. Строки — BGE-M3 и Qwen3-Embedding-8B, их шкалы не совпадают. Столбцы — семейства; они не усредняются. Закрашенные маркеры: опубликованный интервал исключает 0. Незакрашенные маркеры: интервал включает 0, поэтому знак не установлен. У OLMo DPO и Gemma, дообученной на инструкциях, точки последней полосы нет, и они опущены. Сборка `s13-paperb-synthesis-20261107T085555Z-c0f6b853`.

DPO три пары с одинаковым начальным текстом и ни одной пары с разными, поэтому зазор последней полосы отсутствует в обоих пространствах. Эта неидентифицированная полоса не является отрицательным зазором. Для RLVR получены 0.201503 $[-0.134183, 0.201503]$ и 0.334629 $[-0.147232, 0.334629]$. Оба интервала включают 0, поэтому положительный зазор не установлен. Опубликованная таблица не содержит подтверждённых выходов в этих строках OLMo. При трёх или четырёх завершившихся траекториях этот подсчёт выходов нельзя ставить рядом с Qwen как сопоставимую частоту.

Ministral-3-8B Base и Instruct обе завершают 40/40 траекторий. В этой выборке различия по достижению горизонта нет. Такое равенство не означает общего отсутствия эффекта дообучения на инструкциях и не объединяется с Qwen или OLMo. Интервалы последней полосы исключают 0 в обоих пространствах. Base в BGE-M3: 0.138297 $[0.0633819, 0.158376]$ без подтверждённого выхода в опубликованной таблице; Instruct в BGE-M3: 0.150187 $[0.0840649, 0.158143]$ с четырьмя подтверждёнными выходами. Base в Qwen3-Embedding-8B: 0.239919 $[0.126587, 0.271944]$; Instruct в Qwen3-Embedding-8B: 0.224079 $[0.139027, 0.228082]$. Положительный зазор в этом семействе сосуществует с ненулевым числом выходов у Instruct.

Gemma-4-12B задаёт границу положительного зазора. Base завершает 38/40 траекторий. Base в BGE-M3: -0.010628 $[-0.0377395, -0.00608505]$. Интервал целиком ниже 0: это установленный отрицательный зазор. Base в Qwen3-Embedding-8B: 0.0141659 $[-0.0208935, 0.0186512]$. Этот интервал включает 0, поэтому знак не установлен. Общий знак для двух пространств не установлен. Опубликованная строка Base содержит 15 подтверждённых выходов при числе строк таблицы режимов повторения, соответствующем этим 38 завершившимся траекториям. Версия, дообученная на инструкциях, завершает 0/40. У неё нет зазора последней полосы в обоих пространствах. Отсутствие точки не является сменой знака. Контраст Gemma не позволяет установить причинную роль устройства внимания. На рисунке 1 собраны интервалы NF4. Клетки без точки последней полосы опущены, а не изображены нулём.

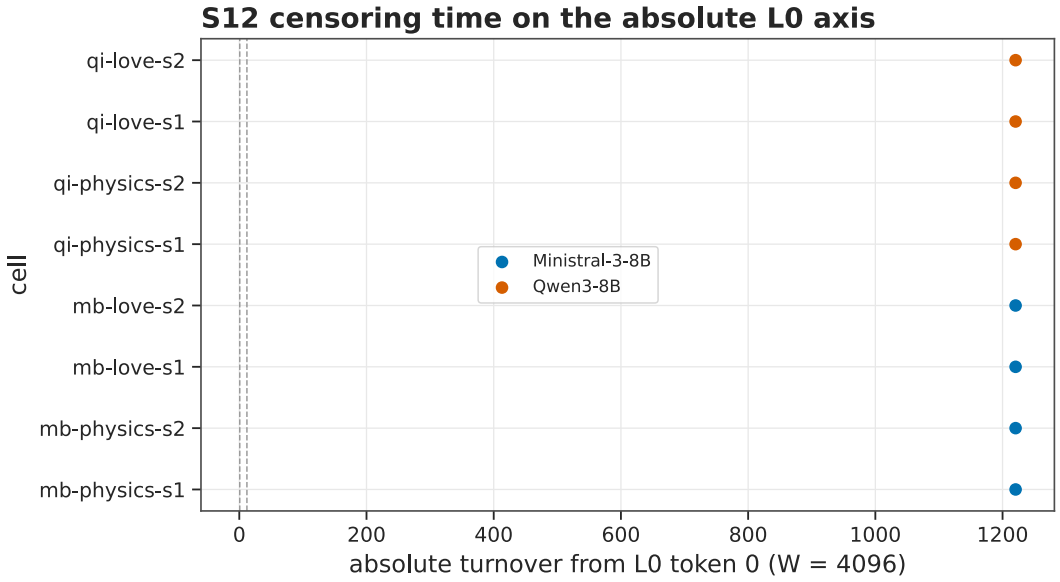


Рис. 2: Момент цензурирования восьми отобранных режимов повторения по часам, начинающимся с первого токена серии из двенадцати оборотов. Все восемь клеток находятся на обороте 1220.5. Пунктир отмечает подтверждение режима на 0.75 и конец той серии на 12.0. До общей остановки подтверждённого выхода не наблюдалось. Это не оценка среднего времени выхода.

4.4 Длительное наблюдение отобранных режимов повторения

Восемь продолжений взяты из условий с уже подтверждённым режимом повторения: Ministral-3-8B Base NF4 и Qwen3-8B Instruct NF4, начальные тексты `physics` и `love`, потомки `s1` и `s2`. Заранее заданное правило отбора ранжировало версии по числу траекторий, всё ещё находившихся в режиме повторения на коротком горизонте, а затем выбирало начальные тексты и потомков по времени подтверждения и фиксированным правилам разрешения совпадений. Поэтому оно выбирает условия, уже показавшие устойчивое повторение, а не репрезентативную выборку начальных текстов. Это не выборка языковых моделей; два семейства подсчитываются, а не объединяются в одну частоту. Каждая траектория достигает 4,999,168 исходных токенов, отсчитанных от первого токена серии из двенадцати оборотов (L0). Отметка подтверждения режима в каждой строке — 0.75 оборота. Через этот горизонт наблюдается 0/8 подтверждённых выходов. τ_{escape} остаётся пустым, флаг цензурирования истинен. Общая остановка — 1220.5 оборота, то есть 1219.75 оборота после отметки подтверждения. На рисунке 2 показан этот момент цензурирования.

Для этих восьми режимов наблюдение убедительно: поверхностный режим, уже существовавший на 0.75 оборота, сохраняется к моменту цензурирования. Оно не оценивает частоту возникновения такого режима, не устанавливает среднее время до выхода и не показывает, что режим постоянен. Пустое время выхода при правом цензурировании — отсутствие наблюдаемого выхода, а не доказательство поглощающего состояния.

4.5 Что не было установлено

Программа также ставила вопросы о валидированной модели состояний, семантическом времени полураспада, температурной границе и зависимости от W, которую можно было бы назвать законом масштабирования. Эти результаты не получены. Их неполучение не доказывает отсутствие соответствующих явлений во всех режимах. Эти измерения не достигли цели, и статья не выдаёт это за положительные результаты.

Модель состояний не прошла валидацию. В каждой строке таблицы устойчивости этапа 3 `validated` равно 0. Оценённые числа макросостояний неустойчивы к числу микросостояний и к выбору пространства эмбеддингов. Ячейка k-means в этом анализе — микросостояние. Это не семантическое состояние. Гипотеза H1 о метастабильных семантических состояниях в виде марковской модели состояний не поддержана на этой выборке. Текстовый режим повторения не заменяет отсутствующую валидацию.

Время полураспада семантической памяти — время, за которое исчезает половина заданной меры информации о начальном тексте, — не измерялось. Зазор между начальными текстами — другая величина. Он может оставаться положительным, потому что две траектории продолжают повторять сходный текст. Это не время полураспада.

Субдиффузия не была показана как сохранение смысла. В сетке температура–окно этапа 4 для `or-qwen3-8b` чистый показатель среднего квадрата смещения определён только при температуре 1.5, где находятся незацикленные клетки, и каждый определённый показатель ниже 1. При температурах 0.3, 0.7 и 1.0 как для W=4096, так и для W=8192 зациклены 4/4 траектории (n=4 на клетку), поэтому чистого показателя для интерпретации нет. При температуре 1.5 для W=4096 зациклены 0/4, а для W=8192 — 2/4. Само повторение удерживает траекторию в небольшой области пространства представлений. Показатель ограниченного движения на зацикленной панели или субдиффузионный показатель при единственной незацикленной температуре не доказывает сохранение смысла. Контраст 4/4 против 0/4 при W=4096 не является температурным законом семантических режимов. Два окна на одном генераторе не образуют закона масштабирования по W.

Токи между семантическими состояниями не получены. Нет валидированного макросостояния, на котором можно было бы определить ток. Контрфактические контрасты текстов-близнецов reactor и waterloo содержат лишь две согласованные стохастические пары на семейство близнецов и имеют низкую статистическую мощность. Их строки последней полосы не приводятся здесь как результат о расхождении, и эквивалентность продолжений текстов-близнецов не утверждается.

5 Ограничения

Процесс использует re-prompt. Каждый блок получен из нового промпта, содержащего текущий хвост. Экспериментальный движок повторяет этот вызов и после полного блока, и после ранней остановки. Непрерывный кэш ключей и значений под скользящей маской не измерялся. Поэтому влияние непрерывного кэша остаётся невыясненным. То же ограничение не позволяет считать результаты описанием обычного чата или агентного цикла.

Тема и стиль не разделены. Каждой доменной метке соответствует один текст. Содержание, лексика и регистр переплетены. Поэтому зазор, обусловленный начальным текстом, — слабый инструмент для любых утверждений о семантической памяти. Родственные режимы могут разделять стиль повторения и давать положительный зазор без сохранённого утверждения.

Матрица семейств охватывает узкий режим. Температура равна 0.3, окно имеет одно значение W, сериализация — сырые байты, основное квантование — NF4. Контроли INT8 предусматривают десять траекторий на клетку, а не сорок. В некоторых контролях лишь три или четыре пары с одинаковым начальным текстом, а их интервалы включают 0. Они не изолируют эффект квантования; согласованный контроль BF16 не выполнялся. BGE-M3 вычислялся локально. Qwen3-Embedding-8B для матрицы семейств предоставлялся через внешний API, поэтому два пространства — также два вычислительных конвейера. Недетерминизм провайдера на этих горизонтах не переизмерялся. В более раннем аудите внешних API доля точных совпадений составляла 100% для glimmer, 60% для Qwen, 20% для Gemma и 20% для обеих версий GPT-oss.

Условие завершения меняет выборку. OLMo DPO даёт три завершившиеся траектории и ни одной пары между разными начальными текстами. Дообученная на инструкциях Gemma не даёт ни одной. В таблице режимов повторения Qwen3-8B Base отсутствует `recipe`, тогда как Instruct сохраняет его в 4/4 случаях. Зазор по выжившим отвечает на иной вопрос, чем зазор по запланированному

дизайну. Статья сообщает и число завершений, и условный зазор, не трактуя второй так, словно первое было сбалансировано.

Эмбеддинги первого эксперимента с занятостью утрачены. Это ограничение относится только к той панели. Репликация укрепляет вывод о знаке зазора занятости, а таблицу 1 можно пересчитать по её собственным каталогам запусков. Архивные интервалы таблицы 2 — нельзя. Статья не обещает, что каждое более раннее число за пределами этой панели можно воспроизвести побитно. Выборка через внешний API и прежде не была детерминированной.

Длинная когорта отобрана, а каждый горизонт конечен. Восемь длинных траекторий выбраны из уже устойчивых режимов повторения по правилу, зафиксированному до продления. Горизонт матрицы семейств — двенадцать оборотов. 1220.5 оборота — момент цензурирования. Ни одно из этих значений не означает бесконечного продолжения. Последняя полоса репликации эксперимента с занятостью также соответствует двенадцати оборотам.

Способ устранения проблемы не проверяется. Измерения не показывают, как улучшить память агентов, выполнение задач или качество длинного текста. Nucleus sampling, штрафы за повторение и поиск не были экспериментальными вмешательствами. Диагностическое описание режима отказа не является его исправлением.

6 Обсуждение

После физического удаления исходного промпта продолжение собственного текста при этом блочном re-prompt может долго сохранять текстовые повторы и статистическую зависимость от начального текста. Достижение горизонта и устойчивость режима повторения и зависимости различаются между исследованными семействами и версиями. Это разные исходы измеренного ядра.

Положительный зазор установлен в репликации, у Qwen3-8B и Ministral-3-8B NF4 в обоих пространствах, а также у OLMo-3-7B Base в обоих пространствах. Для OLMo SFT результат смешанный, для OLMo DPO — неидентифицированный, а для OLMo RLVR зависимость не установлена. У Gemma-4-12B Base зазор установленно отрицателен в BGE-M3, а знак в Qwen3-Embedding-8B не установлен. Положительная различимость имеет границу внутри этого исследования. Эта граница ограничивает обобщение. Она не является архитектурным объяснением.

В таблице режимов повторения Qwen3-8B повторы, несущие поздний зазор, обычно подтверждаются до выхода начального текста из окна. Длинная когорта затем показывает, что восемь таких режимов, отобранных из условий с многочисленными устойчивыми режимами, не имеют подтверждённого выхода через 4,999,168 исходных токенов каждый. Долговечность отобранного режима — иное утверждение, чем позднее возникновение режима или универсальное время полураспада. Измерения не устанавливают ни семантической памяти, ни валидированного набора метастабильных состояний, ни циркуляции между такими состояниями. Модель состояний не прошла валидацию. Время полураспада не измерялось. Токи между семантическими состояниями не получены. Температурная сетка не установила границу между семантическими режимами, а два окна не установили закон масштабирования.

В литературе уже есть повторение (Holtzman et al., 2020; Xu et al., 2022), марковское описание генерации с конечным окном (Zekri et al., 2024), циклы перефразирования (Wang et al., 2025) и семантический дрейф при итерировании целого текста (Geng et al., 2026). Эта запись добавляет различение процессов и явный учёт: вытеснение исходного промпта фиксируется, достижение горизонта не скрывается внутри условной доли режимов повторения, отрицательные клетки остаются в таблицах, длинное наблюдение цензурировано, а интерпретации, к которым подталкивает геометрия, проверяются против этих фактов. Zekri et al. (2024) дают результат о единственности для ядра токенной выборки с полным носителем при выполнении их предпосылок. Положительный зазор в эмбеддингах повторяющегося текста совместим с несколькими областями длительного пребывания в этом пространстве. Он не является вторым стационарным распределением токенной цепи.

Практическое значение результата — диагностическое. При длительном продолжении собственного текста можно рассматривать достижение горизонта, режим повторения и зазор начальных текстов как отдельные признаки и ожидать их зависимости от версии модели. Статья не говорит, какое изменение декодирования, квантования или механизма памяти помогло бы. Это был бы другой эксперимент.

7 Воспроизводимость

Эта рукопись объединяет закрытые запуски генерации и анализа. Она не добавляет сгенерированных траекторий, эмбеддингов или заново оценённых результатов. Конфигурации экспериментов и манифесты фиксируют ревизию кода, случайные начальные значения, ревизии токенизаторов, провайдера и настройки версий моделей. Ревизии локальных моделей и рецепт квантования заданы в `configs/models/generators_local_paperb.yaml`; байты начальных текстов — в `configs/seeds/seed_bank_v1.yaml`. Каждый включённый рисунок сохраняет закоммиченные данные в табличном формате и метаданные рядом с изображением. Проверка сборки `afterlife review -stage s13` проверяет механическую целостность записи синтеза. Она не устанавливает научную обоснованность и не восстанавливает отсутствующие архивные векторы.

Идентификаторы для приведённых выше утверждений:

- Таблица режимов повторения эксперимента с занятостью: `s5-degeneracy-20260906T030145Z-deb4c3bd` (генерация `s5-lock-occupancy-20260905T164327Z-6780902f`, каталоги не подлежат восстановлению).
- Генерация репликации эксперимента с занятостью: `s5-lock-occupancy-repl-20260907T091450Z-e8452acb`; эмбеддинги `s5-embed-lock-occupancy-repl-20260907T175131Z-4e48f831`, `s6-embed-third-space-20260907T181515Z-bcde0a11`.
- Qwen3-8B NF4: `s9-paperb-qwen-base-nf4-20260912T014645Z-f55767bc`, `s9-paperb-qwen-instruct-nf4-20260911T054758Z-c54e2ab6`.
- OLMo-3-7B NF4: `s10-paperb-olmo-base-nf4-20260916T204957Z-6d7b4be3`, `s10-paperb-olmo-sft-nf4-20260917T142201Z-2b7b5b6e`, `s10-paperb-olmo-dpo-nf4-20260918T000412Z-64ad9f9f`, `s10-paperb-olmo-rlvr-nf4-20260918T022536Z-30b5b3fc`.
- Ministral-3-8B и Gemma-4-12B: `s11-paperb-ministral-base-nf4-20260919T130616Z-5896956b`, `s11-paperb-ministral-instruct-nf4-20260920T065557Z-a3093ea2`, `s11-paperb-gemma4-base-nf4-20260921T003925Z-6cae9981`, `s11-paperb-gemma4-it-nf4-20260922T160427Z-3b5b9427`.
- Опубликованные зазоры матрицы семейств: `s13-paperb-synthesis-20261107T085555Z-c0f6b853`.
- Восемь длинных траекторий: список `run_id` в `artifacts/stage-12/tau_escape/tau_escape.meta.json`.
- Валидация модели состояний: `s3-dynamics-20260901T204521Z-f21d5908`, `s3-dynamics-20260901T204549Z-b7c4d0c9`.
- Температурная сетка: `s4-w4096-new-temps-20260904T103121Z-589c8eb1`, `s4-w8192-20260904T120057Z-ce82ce55`.

Список литературы

Mingguang Chen, Licheng Wang, and Bo Qu. The horizon gap: Planning, memory, execution, training, and evaluation for long-horizon LLM agents. *arXiv preprint arXiv:2608.06663*, 2026.

Mingmeng Geng, Amr Mohamed, Guokan Shang, Michalis Vazirgiannis, and Thierry Poibeau. Markovian generation chains in large language models. In *Findings of the Association for Computational Linguistics: EMNLP 2026*, pp. 46847–46865, Budapest, Hungary, 2026. Association for Computational Linguistics. URL https://aclanthology.org/2026.findings-emnlp.2188/.

Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. The curious case of neural text degeneration. In *International Conference on Learning Representations*, 2020.

Ting-Wen Ko and Jonas Geiping. Attractor states emerge in multi-turn LLM conversations. *arXiv preprint arXiv:2606.30571*, 2026.

Amr Mohamed, Mingmeng Geng, Michalis Vazirgiannis, and Guokan Shang. LLM as a broken telephone: Iterative generation distorts information. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 7493–7509, Vienna, Austria, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.acl-long.371. URL https://aclanthology.org/2025.acl-long.371/.

Fabian Paul, Hao Wu, Maximilian Vossel, Bert L. de Groot, and Frank Noé. Identification of kinetic order parameters for non-equilibrium dynamics. *The Journal of Chemical Physics*, 150(16):164120, 2019. doi: 10.1063/1.5083627. arXiv:1811.12551.

Jérémy Perez, Grgur Kovač, Corentin Léger, Cédric Colas, Gaia Molinaro, Maxime Derex, Pierre-Yves Oudeyer, and Clément Moulin-Frier. When LLMs play the telephone game: Cultural attractors as conceptual tools to evaluate LLMs in multi-turn settings. In *International Conference on Learning Representations*, 2025. OpenReview hash dbdea7859f1d2fc10f2c9e79b8f5ae54.

Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. AI models collapse when trained on recursively generated data. *Nature*, 631:755–759, 2024. doi: 10.1038/s41586-024-07566-y.

Heng Wang, Jielin Qiu, Wenting Zhao, Cheng Qian, Liangwei Yang, Jiawei Han, Heng Ji, Silvio Savarese, Shelby Heinecke, and Huan Wang. Random attention: Rethinking KV cache eviction for efficient reasoning. *arXiv preprint arXiv:2609.03430*, 2026.

Zhilin Wang, Yafu Li, Jianhao Yan, Yu Cheng, and Yue Zhang. Unveiling attractor cycles in large language models: A dynamical systems view of successive paraphrasing. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 12740–12755, Vienna, Austria, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.acl-long.624. URL https://aclanthology.org/2025.acl-long.624/.

Hao Wu and Frank Noé. Variational approach for learning Markov processes from time series data. *Journal of Nonlinear Science*, 30:23–66, 2020. doi: 10.1007/s00332-019-09567-y. arXiv:1707.04659.

Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. Efficient streaming language models with attention sinks. In *International Conference on Learning Representations*, 2024. URL https://arxiv.org/abs/2309.17453.

Jin Xu, Xiaojiang Liu, Jianhao Yan, Deng Cai, Huayang Li, and Jian Li. Learning to break the loop: Analyzing and mitigating repetitions for neural text generation. In *Advances in Neural Information Processing Systems*, 2022.

Oussama Zekri, Ambroise Odonnat, Abdelhakim Benechehab, Linus Bleistein, Nicolas Boullé, and Ievgen Redko. Large language models as Markov chains. *arXiv preprint arXiv:2410.02724*, 2024.