

Долговременная динамика блочной самообусловленной языковой генерации после вытеснения промпта Semantic Afterlife

Adam Cage

Аннотация

Языковая модель, чей вход усечён до последних W сгенерированных токенов, продолжает работу после того, как исходный промпт покинул это окно. Мы изучаем *блочное ядро повторного промптинга* $Y_k^{(B)} \sim P_\theta(\cdot \mid X_k; B, \tau)$, $X_{k+1} = \text{Tail}_W(X_k \oplus Y_k^{(B)})$, при $B=1024$ и $W=4096$ ($B/W=0.25$) на одном instruct-генераторе. После полного вытеснения seed текстовый repetition lock — типичный исход при $T=0.3$ (19/20 доменных траекторий). Last-band occupancy сохраняет различимость десяти фиксированных seed-текстов (F4, between-seed); этот зазор — not recovered prompt memory (H2). Гипотеза H1 (валидированные марковские модели состояний) не поддержана. Скользящий нативный KV-кэш мы не измеряли. Degeneracy — это выборка, а не фильтр, который применили и потом забыли.

1 Введение

Пусть $X_k \in V^W$ — последние W токенов генератора. Объект этой статьи — не потоковое скользящее внимание. Это блочное ядро

$$Y_k^{(B)} \sim P_\theta(\cdot \mid X_k; B, \tau), \quad X_{k+1} = \text{Tail}_W(X_k \oplus Y_k^{(B)}). \quad (1)$$

После счётчика генерации $g = W$ seed физически отсутствует во входе модели (полное вытеснение). Последующая траектория — *afterlife*. Научный вопрос: удерживает ли эта траектория идентичность seed, занимает ли lock с меткой домена, или диффундирует.

На этот вопрос легко ответить неправильно. Зацикленная траектория занимает одну точку в пространстве представлений и даёт удержанный mean-squared displacement по причинам, не имеющим отношения к семантике. Degeneracy помечается до того, как читается геометрия.

Эксперименты — этапы 0–6 проспективно заданного, версионизируемого последовательного исследования с документированным адаптивным перепланированием между этапами (docs/research-plan.md). Они не устанавливают H1, H5 и не дают результата для языковых моделей как класса.

Раздел 2 помещает afterlife в проверенную литературу. Раздел 3 определяет ядро, два момента вытеснения и принудительное продолжение. Раздел 4 сообщает о lock при низком T . Раздел 5 сообщает last-band occupancy доменов. Раздел 6 фиксирует, чего дизайн не может установить. Раздел 7 перечисляет оставшиеся угрозы валидности.

2 Связанные работы

Мы цитируем только источники, помеченные VERIFIED в журнале литературы проекта.

Zekri et al. [2024] изучают авторегрессивную генерацию как марковскую цепь на контексте и при сжатии next-token ядра в полной вариации доказывают существование единственного стационарного распределения. Эта теорема — правильный нуль для единственного долговременного закона. Это не измерение last-band occupancy после вытеснения.

Протоколы telephone-game и paraphrase передают *весь* предыдущий текст под инструкцией [Perez et al., 2025, Mohamed et al., 2025, Wang et al., 2025, Geng et al., 2026]. Наше состояние — конечный хвост с явным вытеснением промпта и многими оборотами навязанного W . Ko and Geiping [2026] описывают аттракторы, обусловленные собеседником; в этом протоколе собеседника нет. Chen et al. [2026] разделяют horizon, context и memory; мы навязываем W усечением и начинаем после того, как seed покинул это окно. Wang et al. [2026] закрепляют промпт и случайно вытесняют сгенерированные reasoning-токены для сжатия KV-кэша; мы полностью вытесняем seed и продолжаем без инструкции.

Дегенерация поверхностной формы при максимизирующем декодировании задокументирована [Holtzman et al., 2020]. Самоподкрепление повторного предложения — ближайшее альтернативное объяснение lock [Xu et al., 2022]. Коллапс при обучении на рекурсивно сгенерированных данных [Shumailov et al., 2024] — другой объект: мы никогда не дообучаем. Марковская методология из молекулярной динамики [Wu and Noé, 2020, Paul et al., 2019] — инструментарий, который применил этап 3; инструментарий не есть результат.

3 Протокол

3.1 Генератор, окно и P1

Occupancy использует `or-qwen3-8b` (Qwen3-8B-Instruct через OpenRouter; served provider Alibaba на каждом завершённом occupancy-шаге), $W=4096$, $T=0.3$, блок $B=1024$, так что $B/W=0.25$, чанки анализа по 1024 токена генератора, без перекрытия, и двенадцать оборотов W . Механизм продолжения — `raw_completion`, не `assistant_prefill` и не `chat_instructed`. Протокол P1 — повторный промптинг: последние W токенов перекодируются и отправляются как новый промпт. P1 и механизм продолжения — разные оси (глоссарий). Конструкция входа — не скользящий нативный KV-кэш (протокол P2).

Вытеснение имеет два момента. *Начало вытеснения* — $W - L_0$: окно впервые заполняется, и следующий сгенерированный токен может вытолкнуть токен seed. *Полное вытеснение* — $g = W$: ни одного токена seed не осталось. Last-band occupancy использует оборот ≥ 1 , то есть полное вытеснение, а не момент заполнения. Исторический generate JSONL хранил `horizon_tokens = W - L_0`; анализ не читает это поле для F4.

Процесс — *внешне поддерживаемое самообуславливание после повторных попыток остановки*: stop-токены записываются, генерация продолжается. Survival-анализ EOS как поглощающего состояния отложен (Paper B).

3.2 Закон стоимости

Хостовые траты следуют записанному ledger. Аудит этапа 0 стоил \$0.0128. Генерация этапа 1 биллилась \$6.32 на `s1-pilot-core-20260830T134147Z-f1cce9ec`. Хостовая генерация этапа 4 биллилась \$3.4383. Генерация этапа 5 биллилась \$1.3385. Этап 6 использовал кэшированные эмбединги Gemini при хостовых \$0. Хостовые траты проекта на закрытии этапа 6 составляли \$16.34 из потолка \$200. Этот correctness-проход потратил \$0.

Таблица 1: Частоты текстового repetition-lock, ось моделей этапа 2, по температуре, $W=4096$, $n=4$ на ячейку, 95% CI Clopper–Pearson. Источник: `artifacts/stage-2/model-axis/rates/fixed_point_rates_by_temperature.csv`. Смешанные $n=8$ по $T \in \{0.3, 1.0\}$ остаются в `fixed_point_rates.csv` и не являются таблицей $T=0.3$. 0/4 у Gemma при обеих температурах — доказательство существования того, что заморозка этапа 1 не свойство instruct-моделей как класса.

Генератор	$T=0.3$	95% CI	$T=1.0$	95% CI
or-qwen3-8b	3/4	[0.194, 0.994]	4/4	[0.398, 1]
or-gemma-4-31b	0/4	[0, 0.602]	0/4	[0, 0.602]
or-gpt-oss-120b	4/4	[0.398, 1]	4/4	[0.398, 1]
or-muse-glimmer-30b	2/4	[0.068, 0.932]	0/4	[0, 0.602]
or-gpt-oss-20b	не завершили design T			

3.3 Degeneracy — это выборка

Траектория помечается текстовым repetition lock, когда калиброванная статистика повторов пересекает порог, выведенный из корпуса человеческой прозы (Carroll и Darwin): средний 3-gram Jaccard 0.083 и Jaccard позднего окна 0.0122. Детектор сообщает о почти-рекуррентном текстовом режиме (неподвижная точка или короткий цикл), а не о точном тесте периода-1. Эти два числа не перенастраиваются.

На оссурансу-панели 19/20 доменных траекторий и 1/2 love- траекторий удовлетворяют правилу lock; у 10/10 доменных seed есть хотя бы один lock. Clopper–Pearson 19/20 равен [0.751, 0.999]. Оссурансу — утверждение о зацикленных траекториях. Геометрия на looping-строке не интерпретируется как удержанный семантический бассейн.

4 Низкотемпературный repetition lock

Этап 1 сгенерировал 48 траекторий на or-qwen3-8b при $W=4096$, целевых $T=131072$ токенов (32 оборота). Правило lock сработало на 45/48 траекториях (94%), включая 24/24 при $T=0.3$ и 21/24 при $T=1.0$. Рисунок 1 показывает кривую domain-gap на этой панели с degenerate-majority; это не не-looping подвыборка.

Lock не универсален среди hosted-генераторов. Таблица 1 разделяет частоты этапа 2 по температуре, $W=4096$, $n=4$ на ячейку, Clopper–Pearson. Ранее опубликованные строки $n=8$ смешивают $T \in \{0.3, 1.0\}$: or-gemma-4-31b — 0/8 ([0, 0.369]), or-gpt-oss-120b — 8/8 ([0.631, 1]), or-qwen3-8b — 7/8 ([0.473, 0.997]). При $T=0.3$: gemma 0/4 ([0, 0.602]), 120B 4/4 ([0.398, 1]), Qwen 3/4 ([0.194, 0.994]). При $T=1.0$: gemma 0/4, 120B 4/4, Qwen 4/4. Направление (F2) — gemma против 120B при обеих температурах. Интервал Qwen при $T=0.3$ включает 0.5.

Плечо prefill-versus-raw на or-qwen3-8b — 7/8 против 8/8; разностный CI Newcombe включает 0 (Fisher $p=1$).

Этап 4 пересёк температуру и окно при $n=4$ на ячейку. При $T \leq 1.0$ и $W=4096$, и $W=8192$ дают 4/4 ([0.398, 1]). При $T=1.5$, $W=4096$ даёт 0/4 ([0, 0.602]); $W=8192$ даёт 2/4 ([0.068, 0.932]). Контраст ячеек 4/4 против 0/4 при $W=4096$ — не температурный закон. Гипотеза H5 (температурное окно не-looping удержанного движения) отсутствует: чистая MSD α определена только при $T=1.5$ и субдиффузионна.

Таблица 2: Частота looping по температуре и окну, этап 4, or-qwen3-8b, $n=4$ на ячейку, CI Clopper–Pearson. Источник: `artifacts/stage-4/grid/looping_rate_by_cell.csv`.

T	$W=4096$	CI	$W=8192$	CI
≤ 1.0	4/4	[0.398, 1]	4/4	[0.398, 1]
1.5	0/4	[0, 0.602]	2/4	[0.068, 0.932]

Does seed identity survive the context horizon? — bge-m3

$W = 4,096$ tokens. Post-horizon mean gap 0.1569, trend -0.00079 per turnover. Separated at the last observed band.




Рис. 1: Domain-gap этапа 1 против оборота в bge-m3 на пилоте из 48 траекторий or-qwen3-8b. Панель с degenerate-majority. Данные: `artifacts/stage-1/separation-bge-m3/seed_separation.data.parquet`.

5 Last-band occupancy

При наличии lock этапы 5–6 спрашивают, остаются ли last-band центроиды десяти фиксированных seed-текстов различимы (between-seed vs within-seed). Двадцать восемь траекторий при $W=4096$, $T=0.3$, $B=1024$, двенадцать оборотов. Generate s5-lock-occupancy-20260905T164327Z-67809 embed s5-embed-lock-occupancy-20260906T030125Z-eab6e484; degeneracy s5-degeneracy-20260906T03014 gemini s6-embed-third-space-20260906T082301Z-588eff8f.

Пусть D_{within} — среднее косинусное расстояние между last-band центроидами одного seed-текста, а D_{between} — среднее между разными seed-текстами. Зазор равен $\Delta_{\text{dom}} = D_{\text{between}} - D_{\text{within}}$. Домен здесь — один размеченный экземпляр seed, не выборка из популяции. Seed помечаются разделёнными, когда 95% CI траекторного bootstrap исключает 0 сверху. Этот оценщик уже ресэмплирует с кратностью (ADR-0019). Независимый пересчёт матрицы пар seed согласуется по точке до < 0.002 во всех трёх пространствах. Опубликованные CI с эмбедингов не пересчитываются: именованные occupancy-run невозстановимы (ADR-0021). Новая генерация чеканила бы новые run_id и новые реализации, а не проверяла опубликованные интервалы.

Таблица 3 сообщает last-band F4. Все три пространства разделены по этому правилу CI: bge-m3 0.201 [0.065, 0.332]; qwen3-embed-8b 0.390 [0.151, 0.593]; gemini-embed-001 0.150 [0.029, 0.266]. Утверждение — согласие знака. Уровни не взаимозаменяемы. Нижняя граница Gemini 0.029 — прохождение NHST, а не architecture-independence. У physics seed 1 47 против

Looping / repetition-lock rate on or-qwen3-8b (P1 raw), $n = 4$ per cell




Рис. 2: Частота looping против температуры на двух окнах, 95% CI Clopper–Pearson, $n=4$. Ячейка $T=1.5$, $W=4096$ — существование не-looping режима на этой модели, а не время перемешивания.

MSD α on non-degenerate trajectories only; $\times = n_{\text{clean}} < 2$ (undefined)




Рис. 3: Чистая MSD α там, где определена (только не-looping ячейки). Отсутствующие точки при низком T — отсутствие H5.

48 чанков, поэтому диагональ last-band D_{within} не определена; F4 использует $n_{\text{within}}=9$ пар. Leave-one-seed-out на матрице сохраняет зазор положительным во всех пространствах (минимум 0.128). Рандомизация within-пар из 54 уникальных конечных пар даёт $p=0.0001$ в каждом пространстве (0/9999 перестановок не меньше наблюдаемого зазора, seed 0). Это тест на десяти фиксированных seed-текстах, не на популяции доменов. Last-band gap — различимость between-seed, а не recovered prompt memory (H2) и не domain memory.

Протокольная диагностика, не заголовок: доменные траектории проводят среднюю долю заполнения 0.853, 95% CI [0.756, 0.936], в последней четверти, при средней доле stop-токенов 0.359.

6 Чего это не показывает

H1 не поддерживается. Этап 3 применил VAMP/PCCA+ на эмбедингах панели этапа 1. validated=0 в каждой ячейке artifacts/stage-3/dynamics/k_stability.md. Implied n_{macro} нестабилен по K и по пространствам эмбедингов. Гипотеза H1 (метастабильные семантические состояния как объект MSM) не поддерживается. Короткоцикловый lock — не валидированное макросостояние.

H5 отсутствует. На сетке этапа 4 нет чистой α при низком T .

Таблица 3: F4 last-band зазор between-seed vs within-seed, десять фиксированных seed-текстов, $n=20$, $n_{\text{within}}=9$. Источник: `artifacts/stage-6/occupancy/domain_separation_last_band.csv`. Separated означает, что опубликованный 95% CI исключает 0 сверху. Опубликованные 95% CI — исходные выходы анализа в этом CSV; исходные оссипансу-векторы невосстановимы (ADR-0021).

Пространство	зазор	95% CI	separated
bge-m3	0.201	[0.065, 0.332]	да
qwen3-embed-8b	0.390	[0.151, 0.593]	да
gemini-embed-001	0.150	[0.029, 0.266]	да

Ten-domain seed gap vs turnover on or-qwen3-8b (P1 raw), $W=4096$ $T=0.3$




Рис. 4: Between-seed last-band gap против оборота в bge-m3 и qwen3-embed-8b на locked-панели этапа 5. Last-band CI исключают 0 сверху в обоих пространствах.

Ф6 не заголовок. Сопоставленные пары реплик — контрфактические нарративы, а не однотокенные фактические переключения. $n=2$ на семейство. Опубликованные CI-колонки twins использовали bootstrap, отбрасывавший кратности ресэмпла (ADR-0019), и здесь не сообщаются как интервалы. Last-band *точечная* Δ в gemini-embed-001 равна -0.012 (все пары) и 0.049 в bge-m3 waterloo. Это no detected divergence / underpowered, а не оссипансу одного lock и не семантический коллапс. Дизайн эквивалентности не утверждается.

Нет универсальных аттракторов. Один instruct-генератор, P1, raw_completion, Alibaba, $T=0.3$. Уже 0/8 у Gemma фальсифицирует универсальность.

7 Ограничения

P1 против скользящего внимания. Каждый токен afterlife производится повторным промптингом последних W токенов. Нативный скользящий KV-кэш (P2) не измерялся. Ни одно предложение здесь не является свидетельством о скользящем внимании.

Один генератор, один протокол, одна температура для оссипансу. F4 — or-qwen3-8b, P1, raw_completion, served provider Alibaba, $T=0.3$, $W=4096$, $B=1024$. P1 — ось повторного промптинга; raw_completion — механизм продолжения. Это не синонимы.

Instruction-tuning и регистр. Оссипансу-генератор — instruct-tuned. Этап 2 уже измерил reviewer-регистр на этой модели. Альтернатива persona/register — last-band центроиды

Ten-domain last-band gap in three embedding spaces




Рис. 5: F4 between-seed last-band gap против оборота в трёх пространствах эмбеддингов на тех же 28 траекториях. Last-band CI исключают 0; нижняя граница gemini равна 0.029. Уровни 0.201 / 0.390 / 0.150 не взаимозаменяемы.

кластеризуются по остаточному стилю инструкции, а не по домену seed — не исключена F4. Хостовой base-модели не было (этап 0). Локальный зонд `gemma-3-1b-pt` при $W=256$ — другое окно.

Принудительное продолжение. Объект — внешне поддерживаемое самообуславливание после повторных попыток остановки. Доля stop в последней четверти 0.359 — confound, который нужно назвать, а не измерение EOS как поглощающего.

Twins, $n=2$. F6 underpowered. Twins — не однофактовые пары. CI от сломанного bootstrap не используются как свидетельство.

Нуль degeneracy. Порог lock — проза Carroll+Darwin. Калибровка масштаба Wikipedia отложена.

Представление. Абсолютные зазоры 0.201, 0.390, 0.150 не согласны. Нижний CI Gemini 0.029 — не architecture-independence.

Недетерминизм провайдера. Точные совпадения этапа 2 составляли 100/60/20/20 процентов по четырём hosted-генераторам. Пары реплик не гарантированы как независимые реализации.

Оскупансу-векторы. Именованные occupancy generate/embed run невосстановимы (ADR-0021). Опубликованные CI траекторного bootstrap — исходные выходы анализа в закомми-ченном CSV, не пересчёт с эмбеддингов. Независимо воспроизводимый вывод F4 в этом проходе — матрица пар seed, leave-one-seed-out и рандомизация within-пар. Новая генерация была бы новой панелью, а не восстановлением этих интервалов.




Рис. 6: Last-band косинусные расстояния в `gemini-embed-001` (иллюстрация попарной матрицы, не число кластеров, не 2-D проекция).

Конечный горизонт. Оссурансу использует двенадцать оборотов, а не бесконечный `afterlife`.

8 Обсуждение

Что установлено на этом генераторе и протоколе: после того как `seed` покидает W , типичная траектория при $T=0.3$ — текстовый `repetition lock`; last-band центроиды всё ещё показывают `between-seed last-band` зазор по десяти фиксированным `seed`-текстам в трёх пространствах эмбедингов (`not recovered prompt memory`, H2).

Что не установлено: H1; H5; мы не можем утверждать `architecture-independence ossurancy`; результат для языковых моделей как класса; P1 против P2; времена перемешивания; коллапс реплик; однофактовая чувствительность `twins`.

Zekri et al. [2024] остаются правильным нулём единственности. Last-band зазоры с меткой `seed` на `locked`-панели совместимы с более чем одной долговременной областью оссурансу в пространстве эмбедингов. Эта совместимость — не доказательство того, что токеничная цепь имеет несколько стационарных мер.

9 Воспроизводимость

Эксперименты через этап 6 закрыты на `git`-коммите `ad1f244`. Этап 7 написал первую рукопись. Этот `correctness`-проход — ADR-0019, ADR-0020 и ADR-0021 на ветке `cursor/tmlr-correctness-a7f7`; он не чеканит `runs/s7`. Хостовые траты прохода — \$0. Тег `GitHub state-latest` — изменяемый указатель восстановления, а не цитируемый архивный объект.

Основные `run_id`:

- Этап 1 generate: `s1-pilot-core-20260830T134147Z-f1cce9ec`
- Этап 1 degeneracy: `s1-degeneracy-20260831T070038Z-b2f6f0c9`
- Этап 1 embed: `s1-embed-pilot-core-20260831T064430Z-f05e6a68`
- Этап 1 separation: `s1-separation-bge-m3-20260831T074042Z-9bf54fbf`
- Этап 2 model axis: `s2-model-axis-20260901T015457Z-ab59afc8`
- Этап 2 mechanism: `s2-mechanism-20260901T071519Z-dfbb173a`
- Этап 2 rates: `s2-rates-20260901T125506Z-41d2e88e`
- Этап 3 dynamics: `s3-dynamics-20260901T204521Z-f21d5908`
- Этап 4: `s4-w4096-new-temps-20260904T103121Z-589c8eb1`, `s4-w8192-20260904T120057Z-ce82ce55`
- Этап 5 generate: `s5-lock-occupancy-20260905T164327Z-6780902f`
- Этап 6 gemini: `s6-embed-third-space-20260906T082301Z-588eff8f`

Список литературы

- Mingguang Chen, Licheng Wang, and Bo Qu. The horizon gap: Planning, memory, execution, training, and evaluation for long-horizon LLM agents. *arXiv preprint arXiv:2608.06663*, 2026.
- Mingmeng Geng, Amr Mohamed, Guokan Shang, Michalis Vazirgiannis, and Thierry Poibeau. Markovian generation chains in large language models. *arXiv preprint arXiv:2603.11228*, 2026.
- Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. The curious case of neural text degeneration. In *International Conference on Learning Representations*, 2020.
- Ting-Wen Ko and Jonas Geiping. Attractor states emerge in multi-turn LLM conversations. *arXiv preprint arXiv:2606.30571*, 2026.
- Amr Mohamed, Mingmeng Geng, Michalis Vazirgiannis, and Guokan Shang. LLM as a broken telephone: Iterative generation distorts information. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 7493–7509, Vienna, Austria, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.acl-long.371. URL <https://aclanthology.org/2025.acl-long.371/>.
- Fabian Paul, Hao Wu, Maximilian Vossel, Bert L. de Groot, and Frank Noé. Identification of kinetic order parameters for non-equilibrium dynamics. *The Journal of Chemical Physics*, 150(16):164120, 2019. doi: 10.1063/1.5083627. arXiv:1811.12551.
- Jérémy Perez, Grgur Kovač, Corentin Léger, Cédric Colas, Gaia Molinaro, Maxime Derex, Pierre-Yves Oudeyer, and Clément Moulin-Frier. When LLMs play the telephone game: Cultural attractors as conceptual tools to evaluate LLMs in multi-turn settings. In *International Conference on Learning Representations*, 2025. OpenReview hash dbdea7859f1d2fc10f2c9e79b8f5ae54.
- Ilia Shumailov, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. AI models collapse when trained on recursively generated data. *Nature*, 631:755–759, 2024. doi: 10.1038/s41586-024-07566-y.

- Heng Wang, Jieliu Qiu, Wenting Zhao, Cheng Qian, Liangwei Yang, Jiawei Han, Heng Ji, Silvio Savarese, Shelby Heinecke, and Huan Wang. Random attention: Rethinking KV cache eviction for efficient reasoning. *arXiv preprint arXiv:2609.03430*, 2026.
- Zhilin Wang, Yafu Li, Jianhao Yan, Yu Cheng, and Yue Zhang. Unveiling attractor cycles in large language models: A dynamical systems view of successive paraphrasing. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 12740–12755, Vienna, Austria, 2025. Association for Computational Linguistics. doi: 10.18653/v1/2025.acl-long.624. URL <https://aclanthology.org/2025.acl-long.624/>.
- Hao Wu and Frank Noé. Variational approach for learning Markov processes from time series data. *Journal of Nonlinear Science*, 30:23–66, 2020. doi: 10.1007/s00332-019-09567-y. arXiv:1707.04659.
- Jin Xu, Xiaojiang Liu, Jianhao Yan, Deng Cai, Huayang Li, and Jian Li. Learning to break the loop: Analyzing and mitigating repetitions for neural text generation. In *Advances in Neural Information Processing Systems*, 2022.
- Oussama Zekri, Ambroise Odonnat, Abdelhakim Benechehab, Linus Bleistein, Nicolas Boullé, and Ievgen Redko. Large language models as Markov chains. *arXiv preprint arXiv:2410.02724*, 2024.